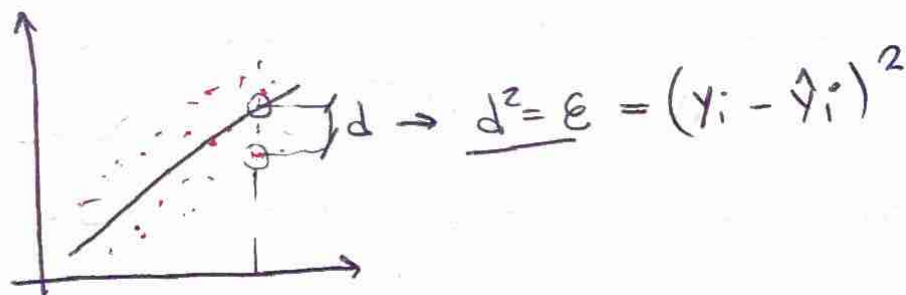


ETAPA 2 - PROJETO 3

WLAS FONTENLA & GUILHERME SCHOVERI

(A) Partindo de uma dispersão, como demonstrado abaixo, podemos calcular o erro como sendo uma distância entre um ponto y "original" (dos dados) e um \hat{y} , que é um ponto em uma reta. O Erro (ϵ) é ao quadrado pois elimina o sinal negativo



Assim, podemos escrever a equação da reta \hat{y} :

$$\hat{y} = \beta_0 + \beta_1 x_i$$

Desse modo,

$$\epsilon = [y_i - (\beta_0 + \beta_1 x_i)]^2$$

A partir do Erro (ϵ) podemos calcular o Erro total de x_1 a x_n , como a soma de todos os erros ϵ_i .

$$\sum_{i=1}^n \epsilon_i = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2 \rightarrow \textcircled{II}$$

Desse modo vamos desenvolver a soma em \textcircled{II}

$$[y_i - (\beta_0 + \beta_1 x_i)]^2 = y_i^2 - 2y_i\beta_0 - 2x_i y_i \beta_1 + \beta_0^2 + 2\beta_0 \beta_1 x_i + \beta_1^2 x_i^2$$


Como a porção anterior que foi "oberta" está em uma somatória, podemos escrever:

$$\frac{\sum y_i^2}{n} = \overline{y^2} \quad \left| \quad \frac{\sum x_i^2}{n} = \overline{x^2} \quad \left| \quad \frac{\sum y_i}{n} = \overline{y} \quad \left| \quad \frac{\sum x_i}{n} = \overline{x} \quad \left| \quad \frac{\sum x_i y_i}{n} = \overline{xy} \right. \right. \right.$$

Ou seja, podemos reescrever tudo como:

$$\varepsilon^2 = n \cdot \overline{y^2} - 2\beta_1 n \overline{xy} - 2\beta_0 \overline{y} + \beta_1^2 n \overline{x^2} + 2\beta_1 \beta_0 \overline{x} + n \beta_0^2$$

A equação acima é em função de duas variáveis β_0 e β_1 , e ambas estão em sua forma quadrática, a partir disso, podemos inferir que o gráfico será dado por uma parabolóide, como abaixo.



Ambos, β_0 e β_1 são parábolas e para isso queremos os pontos no eixo nos quais a outra variável não varia, ou seja a derivada parcial em β_0 e β_1 tem de ser 0 (zero).

$$\textcircled{I} \frac{\partial \mathcal{E}}{\partial \beta_0} = 0$$

$$\textcircled{II} \frac{\partial \mathcal{E}}{\partial \beta_1}$$

Assim,

$$\textcircled{I} \frac{\partial \mathcal{E}}{\partial \beta_0} = -\frac{2n\bar{x}\bar{y}}{2n} + \frac{2\beta_1 n\bar{x}^2}{2n} + \frac{2\beta_0 n\bar{x}}{2n} = 0 \quad / 2n$$

$$= \boxed{-\bar{x}\bar{y} + \beta_1 \bar{x}^2 + \beta_0 \bar{x} = 0}$$

$$\textcircled{II} \frac{\partial \mathcal{E}}{\partial \beta_1} = -\frac{2n\bar{y}}{2n} + \frac{2\beta_1 n\bar{x}}{2n} + \frac{2n\beta_0}{2n} = 0 \quad / 2n$$

$$= \boxed{-\bar{y} + \beta_1 \bar{x} + \beta_0 = 0}$$

A partir de tudo podemos reescrever:

$$\bar{y} - \beta_1 \bar{x} = \frac{\bar{xy} - \beta_0 \bar{x}^2}{\bar{x}} \Rightarrow \beta_1 \left(\frac{\bar{x}^2}{\bar{x}} - \bar{x} \right) = \frac{\bar{xy}}{\bar{x}} - \bar{y}$$

$$\beta_1 = \frac{\bar{xy} - \bar{y}\bar{x}}{\bar{x}^2 - (\bar{x})^2} = \frac{\text{Cov}(x, y)}{\text{Var}(x)}$$

Desse modo, provamos que, o coeficiente angular da reta é dado pela ^{razão} covariância de x e y e a variância de x.

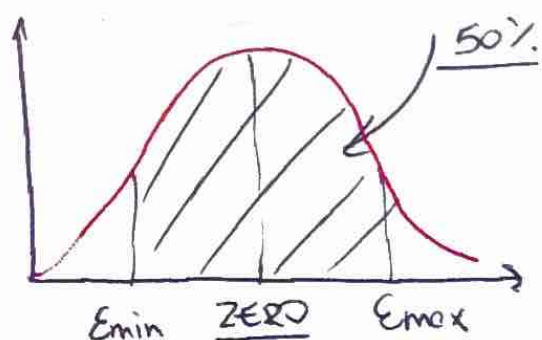
Ⓑ As suposições:

ERRO: O Erro total segue uma distribuição normal com média 0 (zero) e o desvio-
-padrão σ , ou seja:

$$\varepsilon_i = N \sim (0, \sigma^2)$$

Podemos demonstrar seguindo a seguinte pergunta. Qual a probabilidade de termos um erro menor que 50% do valor.

Construindo a normal:



Desse modo, a média está em zero, pois é o ponto assintótico na reta que buscamos ter.

VARIÂNCIA: $\text{Var}(\varepsilon_i) = \sigma^2 = E(\varepsilon_i^2) - E^2(\varepsilon_i)$

FENÔMENO DA HOMOCELASTICIDADE: A variância é constante ao longo da reta.

© Podemos criar duas hipóteses (alternativa e a nula) simples.

$$H_0: \beta_1 = 0 \longrightarrow (\text{não há relação entre } x \text{ e } y)$$

$$H_1: \beta_1 \neq 0 \longrightarrow (\text{há relação entre } x \text{ e } y)$$

Se H_0 for rejeitado, demonstramos que há alguma relação entre x e y , caso ~~caso~~ não rejeitada, dizemos que não há relação entre x e y .

© É possível realizar regressão com quantos variáveis se desejar, mas para cada variável adicionada, mais complicada é a equação.

Por exemplo se, fossemos realizar a regressão de x e w , a equação seria a seguinte:

$$\hat{y} = \beta_0 + \beta_1 \underline{x} + \beta_2 \underline{w}$$

As suposições permaneceriam as mesmas do item b, mas adicionamos mais um eixo e consequentemente, avaliaremos duas curvas normais.

Para o teste de hipóteses, seria igual ao c, mas como no caso b, duplicaríamos o número de hipóteses.

Desse modo, ficaríamos com algo:

| <u>x</u> | | <u>w</u> |
|---|---|---|
| $H_0: \beta_1 = 0$ (não há relação entre x e y) | { | $H_0: \beta_2 = 0$ (não há relação entre w e y) |
| $H_1: \beta_1 \neq 0$ (há relação entre x e y) | | $H_1: \beta_2 \neq 0$ (há relação entre w e y) |